

Análisis del dataset de Coches.net

Esta sección desarrolla el análisis completo de Coches.net, la segunda de las tres fuentes obtenidas mediante web scraping. Se presenta de forma íntegra su descripción, el proceso de extracción, la limpieza de datos y el análisis exploratorio realizado sobre esta plataforma.

Descripción

Coches.net se posiciona como uno de los marketplaces de movilidad más relevantes en España, siendo un referente en la compraventa de vehículos de ocasión, nuevos, km 0 y de renting. Se ha seleccionado como fuente estratégica para este proyecto debido a su elevado volumen de datos, la alta actividad de usuarios y la amplia variedad de categorías disponibles. Todo ello permite obtener información representativa, actualizada y fiable del mercado automovilístico.

El análisis adopta un enfoque que permite estudiar el comportamiento general del mercado dentro de la plataforma. Esta perspectiva resulta clave para comprender cómo se distribuye la oferta entre distintos tipos de vehículos, identificar patrones de precios y detectar tendencias relevantes en función de variables como el tipo de vehículo, la antigüedad o el combustible. Analizar la plataforma en su conjunto también permite entender mejor la estrategia de oferta de Coches.net y su papel como intermediario en el ecosistema digital de compraventa de vehículos.

Extracción de datos

El proceso de extracción de datos se inició con el uso de la librería BeautifulSoup. No obstante, durante su aplicación se detectaron limitaciones importantes: la página web contaba con mecanismos de seguridad que se activaban de forma progresiva a medida que se realizaban nuevas solicitudes, lo que impidió superar los 1.000 registros extraídos. A pesar de estos obstáculos, se decidió incluir el código desarrollado como evidencia del trabajo realizado, ya que refleja la aplicación práctica de las herramientas y conocimientos trabajados a lo largo del curso.

Durante el desarrollo del proyecto se llevaron a cabo dos procesos de extracción de datos en la página de Coches.net con el fin de obtener una visión más completa y comparativa del mercado. Tras varios intentos fallidos con la librería BeautifulSoup, se recurrió al uso de ChatGPT como apoyo para optimizar el proceso de extracción de datos. A partir de esta consulta, se propuso el uso de Selenium, herramienta con la que se logró consolidar una base de datos de 6.867 registros ejecutando el código en un entorno local mediante Visual Studio. Esta extracción se realizó aplicando un filtro específico para furgonetas, segmento con creciente relevancia en sectores como la logística y el transporte, lo que permitió obtener una muestra especialmente útil para su análisis en profundidad.

No obstante, al trasladar el código a Google Colab no fue posible replicar la extracción, a pesar de llevar a cabo las configuraciones, actualizaciones y descargas necesarias. Por este motivo, se incluye el código como evidencia del proceso realizado, y la fase de limpieza de datos se llevará a cabo utilizando la base obtenida en el entorno local.

La segunda extracción se realizó desde la página principal del sitio mediante el uso de Playwright, donde la oferta está mayoritariamente compuesta por turismos, especialmente coches utilitarios y berlinas. En esta ocasión se obtuvieron 3.781 registros adicionales, siguiendo los criterios de estandarización definidos por el equipo de trabajo. Esta muestra proporciona una visión más general del mercado y permite comparar este tipo de vehículos con el segmento de furgonetas obtenido en la extracción anterior.

La combinación de ambas fuentes enriquece considerablemente el análisis, ya que permite contrastar diferencias en precios, características y distribución de la oferta entre distintos tipos de vehículos, ofreciendo así una comprensión más completa del mercado automovilístico representado en la plataforma.

Limpieza y estandarización de datos

Con el objetivo de asegurar la coherencia entre los distintos datasets utilizados en el análisis, se definió un apartado de estandarización de formatos que establece los criterios comunes que todos los conjuntos de datos deben cumplir antes de avanzar

a fases posteriores. Este proceso resulta fundamental para garantizar que las comparaciones y agregaciones entre fuentes sean válidas y fiables.

En las columnas de tipo numérico, concretamente precio, kilómetros y potencia, se eliminaron los caracteres especiales y signos de puntuación que acompañaban a los valores originales, tales como símbolos de moneda, separadores de miles o unidades de medida. Una vez saneados, se asignó a cada columna el tipo de dato numérico correspondiente, asegurando así que pudieran ser utilizadas correctamente en cálculos y análisis estadísticos posteriores.

Durante la revisión de la columna correspondiente al año de matriculación, se identificaron registros que presentaban el año expresado únicamente con dos dígitos, lo que podía generar ambigüedades en la interpretación de los datos. Para corregir este problema, se aplicó una función lambda que convirtió estos valores al formato estándar de cuatro dígitos. Adicionalmente, se estableció el tipo de dato como número entero, garantizando la uniformidad de esta variable en todo el dataset.

Se identificó la presencia de valores nulos en todas las columnas del dataset, a excepción de las columnas fuente y carrocería. Estos valores faltantes corresponden a información que no estaba disponible en la página web en el momento de la extracción, por lo que su ausencia no se considera un error del proceso, sino una limitación inherente a la fuente de datos.

Dado que ninguna de las columnas afectadas presentaba un porcentaje de datos faltantes superior al 3 %, se tomó la decisión de eliminar dichos registros mediante la función `dropna()`. Esta decisión se fundamenta en que, al tratarse de un volumen reducido de registros, su eliminación no compromete la representatividad del dataset, y evita introducir sesgos que podrían derivarse de técnicas de imputación innecesarias.

Adicionalmente, se detectaron 205 registros duplicados en el dataset. Estos registros fueron eliminados mediante la función `drop_duplicates()`, con el fin de garantizar que cada entrada representa un vehículo único y que los análisis posteriores no se vean distorsionados por la repetición de información.

Como resultado de todas las transformaciones aplicadas, se obtuvo un dataframe completamente depurado, libre de valores nulos y registros duplicados, compuesto por 10 columnas y 9.527 registros. Este conjunto de datos constituye una base sólida y fiable sobre la que se desarrollarán las fases de análisis posteriores.

Por último, el dataset resultante se almacenó en un archivo CSV con el objetivo de preservar el estado del procesamiento realizado hasta este punto y facilitar la trazabilidad del trabajo. Este archivo servirá como punto de partida para el análisis exploratorio de datos (EDA), asegurando que dicho análisis se realice siempre sobre una versión limpia, estable y documentada de los datos.

Análisis exploratorio de datos (EDA)

Compresión de los datos

Para la estructuración del análisis exploratorio de datos, se definió en primer lugar un apartado dedicado a la comprensión de la estructura del dataset, cuyo objetivo principal es obtener una visión general del dataframe antes de profundizar en el estudio de sus variables. Este paso inicial resulta imprescindible en cualquier proceso de analítica de datos, ya que permite familiarizarse con la información disponible, detectar posibles inconsistencias que pudieran haber pasado inadvertidas en fases anteriores y establecer una base sólida sobre la que construir el análisis posterior.

En esta sección se comienza por visualizar las columnas que componen el dataframe, las cuales son: marca, modelo, precio, año, kilómetros, combustible, transmisión, potencia, fuente y carrocería. A partir de esta revisión, se elaboró un diccionario de datos en el que se describe el significado, el tipo y el rol de cada una de estas variables dentro del análisis, lo que facilita la interpretación de los resultados y asegura una comprensión común entre todos los miembros del equipo. Este diccionario actúa como documento de referencia durante todo el desarrollo del proyecto.

Variable	Definición
----------	------------

Marca	Fabricante del vehículo
Modelo	Denominación comercial del vehículo dentro de la marca
Precio	Precio de venta del vehículo en euros (€)
Año	Año de matriculación del vehículo
Kilómetros	Distancia total recorrida por el vehículo (en km)
Combustible	Tipo de energía utilizada por el vehículo
Transmisión	Tipo de cambio del vehículo
Potencia	Capacidad de fuerza del motor, medida en CV (caballos de vapor)
Fuente	Origen de los datos
Carrocería	Tipo de estructura exterior o categoría del vehículo

Tabla - Diccionario de variables — dataset Coches.net.

A continuación, se procedió a la visualización de diferentes subconjuntos del dataset con el fin de obtener una primera impresión de los datos. Se consultaron las primeras cinco filas del dataframe, las últimas cinco y una selección aleatoria de otras cinco filas adicionales. Esta combinación de vistas permite no solo comprobar que la estructura del dataset es la esperada, sino también observar la variabilidad de los datos y detectar si existen patrones o valores inusuales que merezcan atención en etapas posteriores del análisis.

Finalmente, se llevó a cabo una revisión de la información general del dataframe mediante la inspección de sus tipos de datos y su estructura global. De este análisis se extrajeron los siguientes hallazgos: el dataset está compuesto por 10 columnas y 9.527 filas, indexadas desde la posición 0 hasta la 9.526, y no presenta ningún valor nulo en ninguna de sus variables, lo que confirma que el proceso de limpieza llevado a cabo en la fase anterior fue efectivo. En cuanto a los tipos de datos, las variables marca, modelo, combustible, transmisión, fuente y carrocería son de tipo object, es decir, variables de texto o categóricas, mientras que las variables precio y kilómetros están almacenadas como números decimales de tipo float, y las variables año y potencia como números enteros. Esta distribución de tipos de datos es coherente con la naturaleza de cada variable y resulta adecuada para el desarrollo de los análisis estadísticos y visualizaciones que se abordarán en los apartados siguientes.

Análisis descriptivo

Con la función describe() se obtuvo un resumen estadístico completo: el precio oscila entre un mínimo de 1.499 € y un máximo de 57.500 €, con una media de 21.838,24 € y una mediana de 21.100 €, cuya proximidad confirma que el filtrado de percentiles resultó efectivo para eliminar los extremos más distorsionadores. El año de matriculación abarca desde 1997 hasta 2026, un rango de 29 años que refleja la amplia diversidad de antigüedad presente en la plataforma. Los kilómetros recorridos oscilan entre 1 km y 426.000 km, con una media de 96.359,07 km y una mediana de 82.100 km, cuya diferencia apunta a una ligera asimetría positiva provocada por vehículos de kilometraje especialmente elevado. La potencia, por su parte, abarca desde 23 CV hasta 555 CV, reflejando la notable diversidad de segmentos representados.

	precio	año	kilometros	potencia
count	9328.000000	9328.000000	9328.000000	9328.000000
mean	21838.241638	2020.604846	96336.483276	131.505467
std	8813.718728	3.293796	67461.776253	46.574125
min	1499.000000	1997.000000	1.000000	23.000000
25%	15500.000000	2019.000000	45600.000000	102.000000
50%	21100.000000	2021.000000	82100.000000	120.000000
75%	27292.500000	2023.000000	132500.000000	150.000000
max	57500.000000	2026.000000	426000.000000	555.000000

Tabla - Matriz de correlación entre variables numéricas — dataset Coches.net.

Complementando el análisis anterior, se aplicó la función `.describe()` sobre las variables de tipo categórico del dataset, lo que permitió obtener una visión general de la diversidad y distribución de cada una de ellas.

En lo que respecta a la marca, se identificaron un total de 57 marcas diferentes, lo que refleja una oferta amplia y variada en la plataforma. Entre todas ellas, Ford es la que mayor presencia tiene en el dataset, con 906 registros, posicionándose como la marca más representada dentro del conjunto de datos analizado.

En cuanto al tipo de combustible, se registraron 5 categorías distintas, siendo el diésel el combustible predominante con 5.038 registros. Este dato es coherente con el perfil general del mercado de vehículos de segunda mano en España, donde los vehículos diésel han tenido históricamente una presencia muy relevante, especialmente en segmentos como las furgonetas y los vehículos de uso profesional.

Respecto a la transmisión, el dataset recoge únicamente 2 tipos: manual y automática. La transmisión manual es claramente dominante, con 6.280 registros, lo que también resulta representativo del parque automovilístico de segunda mano en el mercado español.

En relación con la fuente de los datos, todos los registros del dataset proceden exclusivamente de la plataforma Coches.net, lo que confirma la homogeneidad de la fuente y garantiza que no existen diferencias metodológicas en la extracción derivadas del uso de distintos portales.

Por último, se identificaron 4 tipos de carrocería en el dataset. Dado que una parte significativa del proceso de extracción estuvo orientada específicamente a la obtención de furgonetas, esta categoría resulta ser la más representada, con 5.859 registros, lo que debe tenerse en cuenta a la hora de interpretar los resultados del análisis de forma global.

	marca	modelo	combustible	transmision	fuelle	carroceria
count	9328	9328	9328	9328	9328	9328
unique	57	440	5	2	1	4
top	ford	daily	diesel	manual	coches.net	furgoneta
freq	906	345	5038	6280	9328	5859

Tabla - Distribución porcentual de vehículos por marca — dataset Coches.net.

Para complementar el análisis, se realizó una visualización de las marcas presentes en el dataset junto con su peso porcentual sobre el total. Los resultados muestran que las tres marcas con mayor presencia son Ford, Volkswagen y Mercedes-Benz, con 906, 902 y 895 vehículos respectivamente, lo que representa en torno al 9,7 %, 9,67 % y 9,59 % del total. En el extremo opuesto, la marca con menor representación es LEAP MOTOR, con un único vehículo registrado, lo que supone apenas el 0,01 % del dataset.

En lo que respecta al tipo de combustible, el dataset recoge cinco categorías: diésel, gasolina, híbrido, eléctrico y gas. El diésel es el combustible más habitual, presente en más de la mitad de los vehículos del dataset con un 54 %. A continuación se sitúa la gasolina con un 19,6 %, seguida de los vehículos híbridos con un 13,7 %. Los coches eléctricos representan casi el 10 % del total, mientras que los vehículos a gas tienen una presencia muy reducida, con un 3 %.

En cuanto a la transmisión, las dos únicas categorías presentes son la manual y la automática. La transmisión manual es la opción mayoritaria, con un 67,3 % de los vehículos, mientras que la automática agrupa el 32,7 % restante. Esta distribución es coherente con el perfil del mercado de segunda mano analizado, donde predominan vehículos de uso generalista y de segmentos más asequibles, tradicionalmente asociados a la transmisión manual.

Para cerrar el apartado de análisis descriptivo, se construyó una matriz de correlación entre las variables numéricas del dataset, con el objetivo de identificar posibles relaciones y tendencias entre ellas.

En cuanto a la relación entre el precio y el año de matriculación, se observa una correlación positiva moderada de 0,5, lo que indica que los vehículos más recientes tienden a tener un precio más elevado, un comportamiento completamente esperado en el mercado de segunda mano.

La relación entre el precio y los kilómetros es inversa, con una correlación negativa de -0,5. Esto significa que, a menor kilometraje, mayor suele ser el precio del vehículo, lo que también resulta coherente con la lógica habitual del mercado, donde el desgaste del vehículo influye directamente en su valoración.

Respecto a la correlación entre el precio y la potencia, se obtiene un valor positivo de 0,3, lo que sugiere una tendencia moderada a que los vehículos con mayor potencia presenten precios más altos, algo habitual en segmentos de gama media y alta.

Por último, la relación entre el año y los kilómetros es la más fuerte de las analizadas, con una correlación negativa de -0,7. Este resultado indica que los vehículos más recientes acumulan, de forma general, un menor número de kilómetros, lo cual es completamente lógico teniendo en cuenta el menor tiempo que llevan en circulación.

	precio	año	kilometros	potencia
precio	1.000000	0.575492	-0.506421	0.344638
año	0.575492	1.000000	-0.741297	-0.021693
kilometros	-0.506421	-0.741297	1.000000	-0.001784
potencia	0.344638	-0.021693	-0.001784	1.000000

Tabla - Matriz de correlación entre las variables numéricas del dataset consolidado para el análisis de negocio — dataset Coches.net.

Análisis visual

Para llevar a cabo el análisis visual, se instalaron e importaron las librerías necesarias. En concreto, se utilizaron Matplotlib, Seaborn y Plotly para la generación

de gráficos, junto con Pandas y NumPy para la manipulación y tratamiento de los datos. Adicionalmente, se importaron los módulos `datetime`, para el manejo de fechas, `warnings`, para suprimir mensajes de advertencia durante la ejecución, y `scatter matrix`, para la visualización de relaciones entre variables numéricas. Por último, se configuró el entorno de trabajo para que los gráficos se mostrasen de forma integrada dentro del propio notebook.

El primer gráfico muestra una matriz de correlación, utilizada para visualizar de forma clara las relaciones existentes entre las variables numéricas del dataset. Este tipo de representación facilita la identificación de patrones y dependencias entre variables.

Una de las relaciones más relevantes es la que se establece entre el año de matriculación y el precio, donde se observa que los vehículos más recientes tienden a alcanzar valores más altos. Esto refleja la influencia directa de la antigüedad en el precio de mercado.

También se aprecia que la potencia del vehículo guarda una relación directa con su precio, de modo que los modelos más potentes suelen situarse en rangos de precio superiores, aunque esta relación no es especialmente intensa.

En cuanto al kilometraje, se observa una relación inversa con el precio, lo que indica que los vehículos con menor uso tienden a ser más caros, en línea con el comportamiento esperado en el mercado de segunda mano.

Por último, se confirma que los vehículos más nuevos suelen presentar un menor número de kilómetros recorridos, lo que evidencia una relación coherente entre antigüedad y uso. En conjunto, este gráfico permite comprender de manera más intuitiva cómo se relacionan las principales variables del dataset.




Figura - Histogramas de distribución de precio, kilómetros, año y potencia — dataset Coches.net.

Aunque los histogramas ya se observan en el gráfico anterior, se presentan nuevamente para detallar con mayor precisión las características del dataset. En este análisis se destaca una concentración de precios alrededor de los 20.000 euros. En cuanto a los kilómetros, se aprecia una mayor concentración entre los 50.000 km, respecto a los años se concentran sobre el 2022. Por último, en la variable de potencia se identifica un pico de frecuencia alrededor de los 100 CV, lo que indica una mayor presencia de vehículos con esa motorización.




Figura - Evolución del precio medio por año de matriculación — dataset Coches.net.

Para evidenciar de manera más clara la línea de tendencia entre el precio y el año, se realiza una agrupación de estas variables calculando su media. A partir de este procesamiento, se genera un gráfico de líneas que permite visualizar de forma más evidente la relación previamente mencionada, confirmando que, a mayor año de matriculación, mayor es el valor de venta del vehículo




Figura - Relación entre precio y kilometraje — dataset Coches.net.

Como se ha mencionado anteriormente, la relación entre el precio y los kilómetros es de carácter inverso. Esto se refleja en la gráfica mediante una línea de tendencia descendente, que indica que los vehículos con menor kilometraje tienden a tener un precio más elevado. A medida que aumenta el número de kilómetros recorridos, el precio del vehículo tiende a disminuir.




Figura - Relación entre precio y potencia, segmentada por tipo de transmisión — dataset Coches.net.

En esta gráfica se analiza la relación entre el precio y la potencia de los vehículos, añadiendo además el tipo de transmisión como tercera variable. Se puede observar que, en general, a medida que aumenta la potencia del motor, también aumenta el precio del vehículo. Esto tiene sentido, ya que los coches más potentes suelen ser más caros por sus mejores prestaciones.

Además, se aprecia que los vehículos automáticos suelen tener mayor potencia que los manuales y, por ello, también tienden a ser más caros dentro del dataset. Esto sugiere que los coches automáticos suelen pertenecer a gamas más altas o mejor equipadas, lo que influye directamente en su precio.




Figura - Relación entre kilómetros recorridos y año de matriculación — dataset Coches.net.

En la última gráfica se analiza la relación entre los kilómetros recorridos y el año de matriculación de los vehículos. En términos generales, se observa una tendencia inversa: a medida que aumenta el año (es decir, cuanto más reciente es el vehículo), menor es el número de kilómetros. Esta relación es coherente, ya que los coches más nuevos han tenido menos tiempo de uso.

No obstante, se identifican algunas excepciones puntuales que rompen esta tendencia, como ocurre en ciertos años antiguos (por ejemplo, en torno a 2001), donde aparecen vehículos con pocos kilómetros a pesar de su antigüedad. Estos casos pueden deberse a un uso muy limitado, a vehículos de colección o a posibles particularidades en los datos.

En cuanto a la evolución temporal, la disminución del kilometraje se aprecia de forma más gradual entre los años 2005 y 2014, mientras que a partir de 2015 la caída es mucho más pronunciada. Esto indica que los vehículos más recientes presentan una reducción más significativa en el número de kilómetros, reforzando la relación negativa entre ambas variables.



Hipótesis únicas

Con el objetivo de orientar el análisis hacia el modelo de negocio planteado, se definió un apartado de hipótesis sobre el dataset en el que se formularon una serie de preguntas clave. Este ejercicio resulta especialmente valioso en la fase exploratoria, ya que permite focalizar el análisis en aquellas variables y relaciones que tienen mayor relevancia para los objetivos del proyecto, evitando dispersarse en aspectos que no aportan valor directo a la toma de decisiones.

Las hipótesis planteadas parten de la observación de los datos obtenidos hasta el momento y de la lógica del mercado de vehículos de segunda mano, y tienen como propósito guiar la exploración hacia conclusiones que sean útiles y accionables. A través de estas preguntas se busca comprender mejor el comportamiento de variables como el precio, el kilometraje, la antigüedad o el tipo de vehículo, y analizar cómo se relacionan entre sí dentro del contexto del negocio que se pretende desarrollar.

¿Cuál es el ranking de los vehículos más caros?

Tras aplicar filtros para eliminar valores extremos, se observa que los 10 vehículos más caros del dataset presentan precios comprendidos entre 55.900 y 57.500 euros. Dentro de este grupo, el modelo más costoso es el Mercedes-Benz Clase C, seguido del Audi A4, lo que indica una clara presencia de vehículos de gama media-alta en la parte superior del rango de precios.

Asimismo, al analizar las marcas con los precios más elevados dentro del dataset, se observa el siguiente orden: en primer lugar, Mercedes-Benz, seguido de Audi, Mazda, BMW y, finalmente, Ford.

¿Qué modelos aparecen con mayor frecuencia en el dataset?

Los modelos más frecuentes en el dataset están claramente concentrados en vehículos comerciales. En primer lugar, destaca el Iveco Daily con 345 registros, seguido del Ford Transit Connect con 265 y el Ford Transit con 250. En cuarta

posición se encuentra el Volkswagen Transporter con 232 registros, mientras que el quinto lugar lo ocupa el Ford Transit Courier con 223.

¿Cuál es el precio medio por marca?

Al analizar el precio medio por marca, se observa que las más caras son Polestar, con una media de 44.990 €, seguida de Maserati (40.193,75 €), Ebro (37.644 €), Porsche (36.005,36 €) y Jaecoo (32.866,67 €). Esto indica que estas marcas están asociadas a vehículos de gama más alta o con mejores prestaciones, lo que explica sus precios más elevados.

En el otro extremo, encontramos marcas con precios medios mucho más bajos, como Smart (10.798,55 €), Zhidou (7.990 €), Chevrolet (6.522 €), Lancia (4.990 €) y Dodge (3.450 €). Esto muestra que dentro del dataset hay una gran diferencia entre marcas, ya que conviven tanto opciones económicas como vehículos de gama alta.

¿Qué tipo de combustible presenta el precio más elevado?

El gráfico permite observar diferencias significativas entre categorías. Los vehículos eléctricos presentan el precio medio más elevado, situándose en torno a los 26.100 euros. A continuación, se encuentran los vehículos híbridos, con una media aproximada de 24.100 euros.

En una posición intermedia se sitúan los vehículos de gas, con un precio medio cercano a los 21.100 euros, seguidos por los diésel, cuya media ronda los 20.800 euros. Por último, los vehículos de gasolina son los que presentan el precio medio más bajo, con aproximadamente 17.500 euros.

Estos valores, expresados de forma redondeada, permiten una interpretación más clara de la gráfica interactiva y facilitan la comparación entre los distintos tipos de combustible

¿Existen diferencias de kilometraje según el tipo de carrocería?

Para analizar las diferencias de kilometraje según el tipo de carrocería, se calculó el promedio de kilómetros para cada categoría. Los resultados muestran que las pick-up presentan la media más alta, con aproximadamente 85.000 km, seguidas de las furgonetas con unos 84.000 km y las berlinas con cerca de 82.000 km. Por

último, los vehículos utilitarios son los que registran el menor kilometraje medio, con alrededor de 74.000 km. Estos valores, expresados de forma redondeada, permiten interpretar con mayor claridad la gráfica.

Además, la gráfica no solo muestra los valores medios, sino también la dispersión de los datos y la presencia de valores atípicos. En este caso, se identifican outliers en las carrocerías de furgonetas, berlinas y utilitarios, lo que indica que existen vehículos con kilometrajes significativamente alejados de la media dentro de estas categorías.

¿Existen valores atípicos en los kilómetros

Para analizar la presencia de valores atípicos en los kilómetros, se utilizó el rango intercuartílico. Los resultados muestran un Q1 de 45.600 km y un Q3 de 132.500 km, lo que da lugar a un IQR de 86.900 km. A partir de estos valores, se establecen los límites en -84.750 km y 262.750 km.

Con estos umbrales, se identifican 247 valores atípicos, lo que representa aproximadamente el 2,65 % del total del dataset. Esto indica que, aunque la mayoría de los vehículos se concentra dentro de un rango de kilometraje razonable, existen algunos casos con valores significativamente más altos que se alejan del comportamiento general.

¿Existen valores atípicos en el precio?

A partir del análisis estadístico, se observa que el precio medio es de 21.838,24 €, mientras que la mediana se sitúa en 21.100 €, lo que indica una distribución relativamente centrada, aunque con cierta variabilidad, reflejada en una desviación estándar de 8.813,25 €.

Utilizando el rango intercuartílico (IQR), con un Q1 de 15.500 € y un Q3 de 27.292 €, se establecen los límites para detectar valores atípicos en -2.188,75 € y 44.981,25 €. En base a estos valores, se identifican 328 outliers, lo que representa aproximadamente el 3,52 % del total. Esto confirma la presencia de valores atípicos en el precio, principalmente en el extremo superior, correspondientes a vehículos significativamente más caros que la mayoría del dataset.




Figura 10. Ranking de vehículos y marcas por precio — dataset Coches.net.

Conclusión del análisis de coches.net

Tras el análisis exploratorio realizado, se pueden extraer una serie de conclusiones relevantes sobre el comportamiento del mercado de vehículos de segunda mano recogido en el dataset.

En primer lugar, el precio de un vehículo está condicionado principalmente por tres factores: el año de matriculación, la potencia y el kilometraje. Los vehículos más nuevos y con mayor potencia tienden a ser más caros, mientras que un kilometraje elevado se asocia a precios más bajos. Este patrón es completamente coherente con el funcionamiento habitual del mercado de segunda mano.

En segundo lugar, el tipo de combustible y la marca también juegan un papel importante en la determinación del precio. Los vehículos eléctricos e híbridos son, en promedio, los más caros, mientras que los de gasolina se sitúan en los rangos más bajos. En cuanto a las marcas, existe una diferencia muy notable entre las de gama alta, como Polestar, Maserati o Porsche, y otras con precios medios significativamente menores, como Dodge o Lancia.

En tercer lugar, destaca la fuerte presencia de vehículos comerciales en el dataset. Modelos como el Iveco Daily o el Ford Transit aparecen con mucha frecuencia, lo que refleja que una parte importante de la oferta analizada está orientada al transporte y la logística.

Por último, aunque se detectaron valores atípicos tanto en el precio como en el kilometraje, estos representan una proporción muy pequeña del total y no afectan de forma relevante a las conclusiones obtenidas.

Filtros de negocio

Con el objetivo de construir una base de datos adecuada para los fines del proyecto, se aplicaron una serie de filtros sobre el dataset que permitieron acotar los registros a aquellos vehículos realmente relevantes para el análisis. Los criterios establecidos fueron los siguientes: vehículos con un kilometraje máximo de 120.000 km, año de matriculación a partir de 2020, precio comprendido entre 10.000 y 20.000 euros, y carrocería de tipo berlina, utilitario o furgoneta.

Como resultado de la aplicación de estos filtros, el dataset quedó reducido a 1.632 registros de calidad, listos para ser combinados con los datos extraídos de las demás plataformas de compraventa analizadas en el proyecto. Con esto, el archivo queda preparado para su integración en el dataset unificado, con el que se desarrollarán las fases de análisis más avanzadas.